

ETAPA I – OBJETIVO

OBJETIVO

A partir de bases de dados extraídas do site IMDb (Internet Movie Database), analisar:

- Quais são os 10 filmes com as maiores notas de avaliação dos usuários?
- Quais são os 10 filmes mais populares (com maior números de votos)?

ETAPA 2 – COLETA DOS DADOS

Busca pelos dados

Site: datasets.imdbws.com

Coleta

Os dados foram baixados do site do IMDb para máquina local.

IMDb data files available for download

Documentation for these data files can be found on http://www.imdb.com/interfaces/

name.basics.tsv.gz

title.akas.tsv.gz

title.basics.tsv.gz

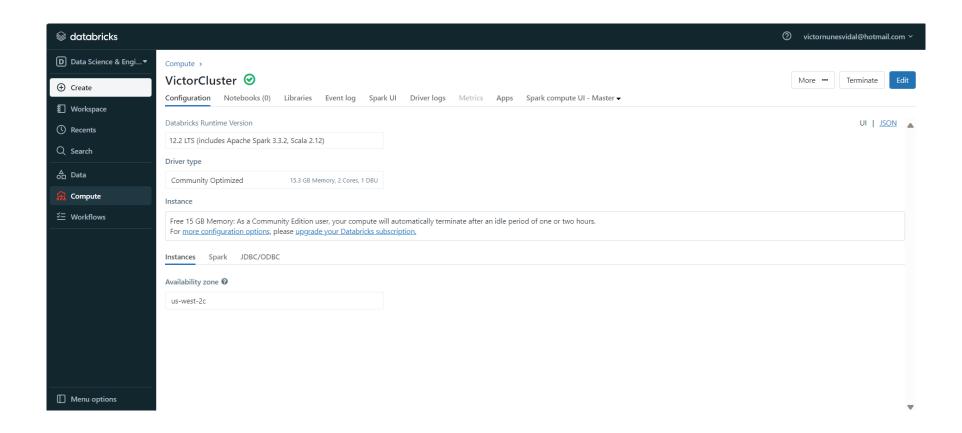
title.crew.tsv.gz

title.episode.tsv.gz

title.principals.tsv.gz

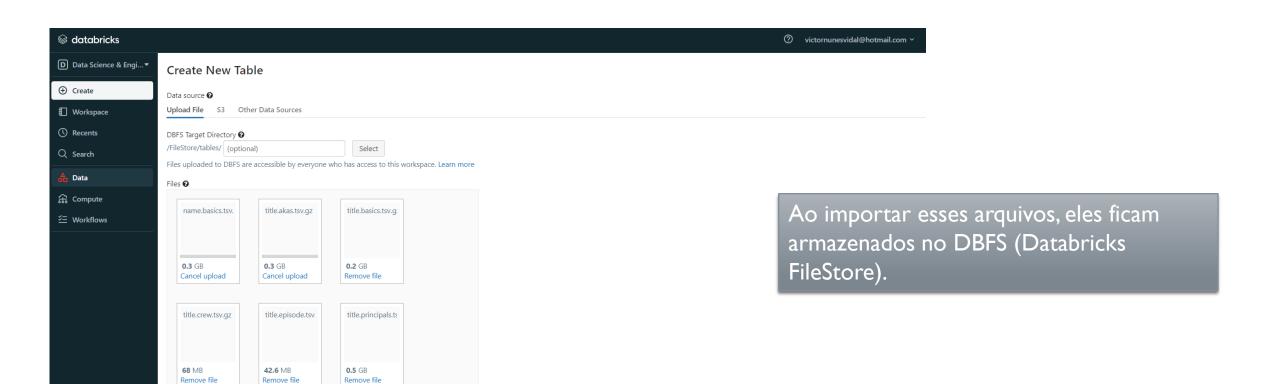
title.ratings.tsv.gz

ETAPA 3 – CRIAÇÃO DE CLUSTER NO DATABRICKS

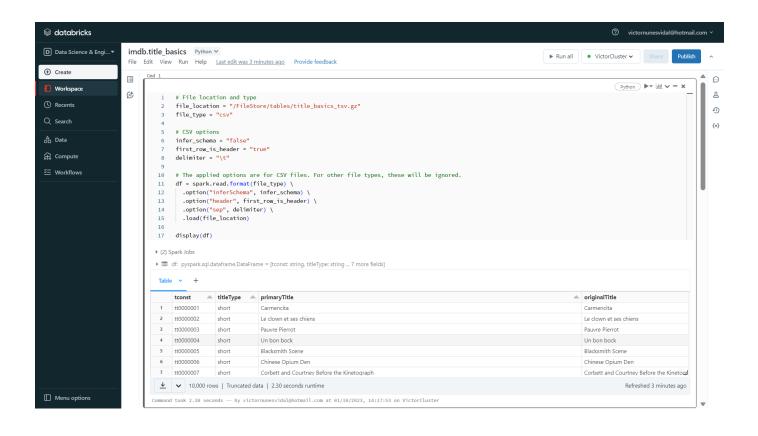


ETAPA 4 – UPLOAD DE ARQUIVOS NO DATABRICKS

Menu options

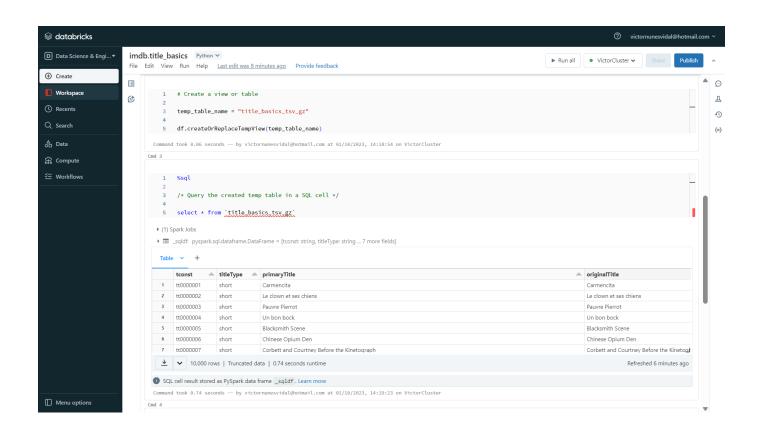


ETAPA 5 – NOTEBOOK PARA CRIAÇÃO DE TABELA NO DATABRICKS



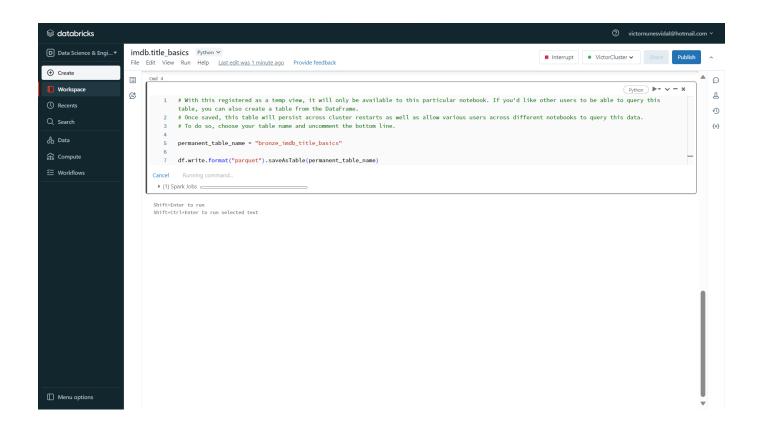
Primeira etapa faz a ingestão do arquivo. Os arquivos utilizados do site do IMDb estão zipados em um arquivo .gz e dentro deles, há um arquivo .tsv. Para que o databricks reconheça esse formato, importei o arquivo como se fosse csv, mas o separador, ao invés de ser vírgula, foi "\t", que é o tipo de separador do arquivo tsv.

ETAPA 6 – NOTEBOOK PARA CRIAÇÃO DE TABELA NO DATABRICKS



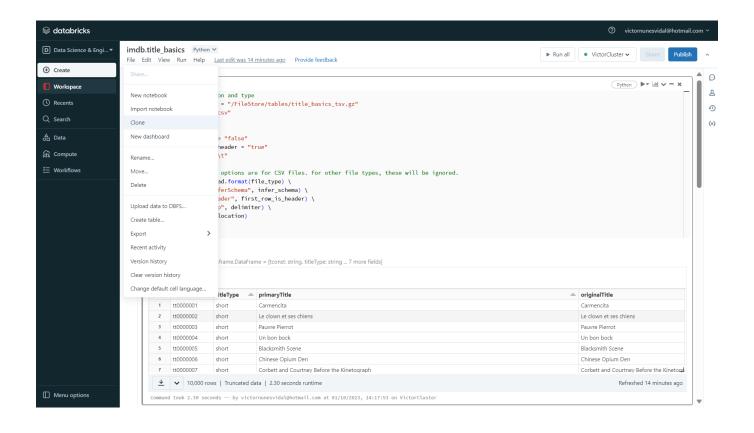
Depois é criada uma tabela temporária para armazenar os dados. O SELECT mostra os dados que estão armazenados nela.

ETAPA 7 – NOTEBOOK PARA CRIAÇÃO DE TABELA NO DATABRICKS



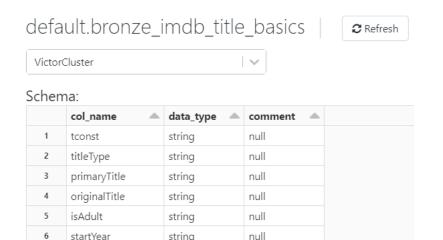
Por último, é criada uma tabela permanente com os dados da tabela temporária.

ETAPA 8 – NOTEBOOK SALVO E DUPLICADO



No Databricks, em File > Clone, é duplicado o notebook e feito o mesmo processo para o outro arquivo que será utilizado nesse trabalho, que é o arquivo que contém as notas e número de votos de cada título do IMDb.

ETAPA 9 – DATA QUALITY

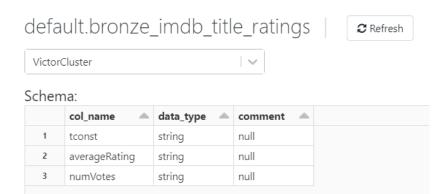


null

string

string

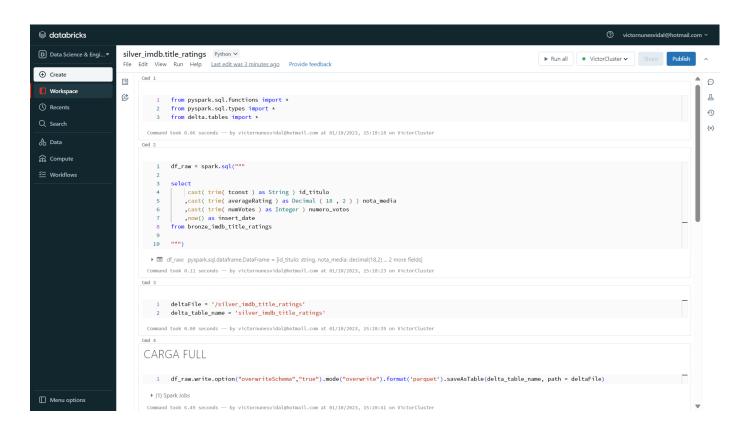
endYear



Ao checar os schemas das duas tabelas importadas, vemos que as colunas estão em formato string. Isso já era esperado, já que não fizemos nenhum tratamento de data type.

Dessa forma, vamos criar dois novos notebooks para essas tabelas bronze, que serão as camadas silver dessas tabelas, onde faremos os tratamentos de data type.

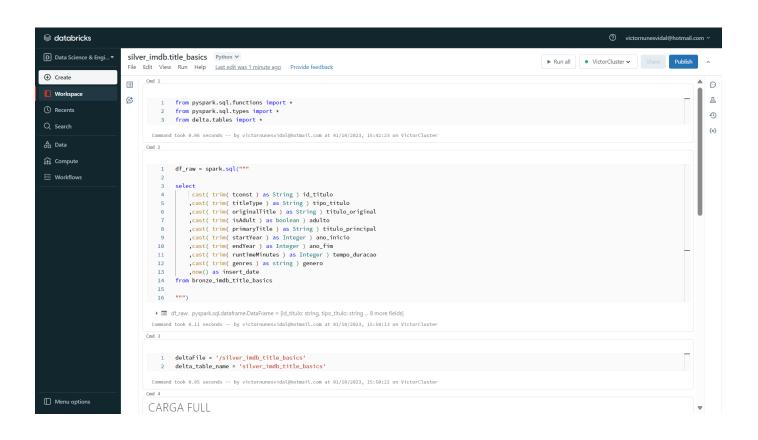
ETAPA 10 – CAMADA SILVER



- Importadas bibliotecas;
- Feito CAST para cada um dos campos indicando o formato correto deles, bem como renomeando-os;
- Utilizada função TRIM para corrigir quaisquer inconsistências comuns em bancos de dados (Exemplo: espaços em branco no final ou no começo do campo);
- Feita carga em tabela silver.
- Os datatypes utilizados aqui foram feitos com base na documentação do site do IMDb: <u>IMDb Non-Commercial</u>

Datasets

ETAPA I I – CAMADA SILVER



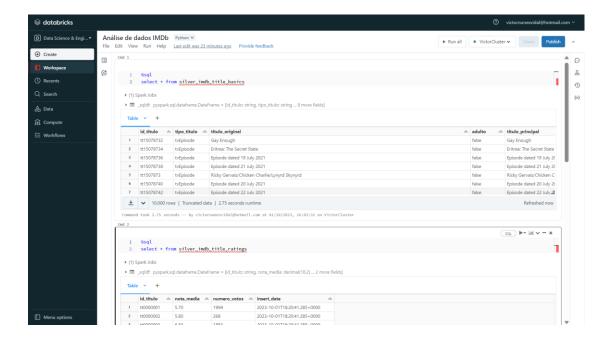
 Mesmo processo feito para tabela imdb_title_basics

ETAPA I I – CONFERÊNCIAS

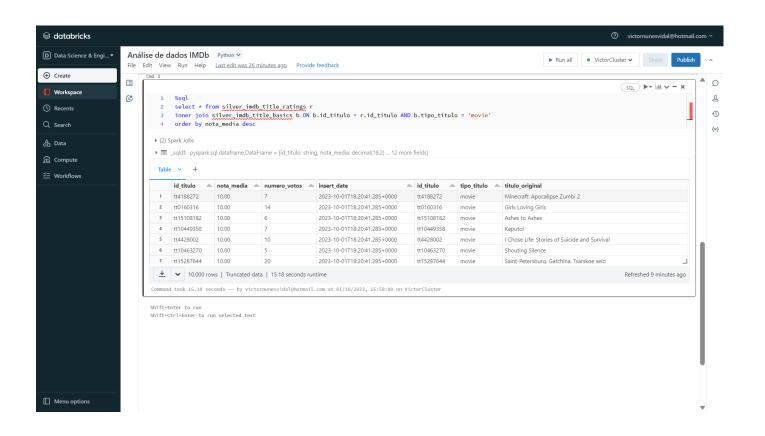
Na interface do Databricks, conferimos que as tabelas já estão disponíveis para consulta:

D Data Science & Engi...▼ Database Tables Create Table Create Databases **Ⅲ** Workspace Q Filter Databases Q Filter Tables ■ bronze imdb title basics default Recents ■ bronze_imdb_title_ratings Q Search ■ silver imdb title basics A Data ■ silver_imdb_title_ratings Compute ✓ Workflows

Fazendo SELECT nas tabelas da camada silver, também já visualizamos os dados:



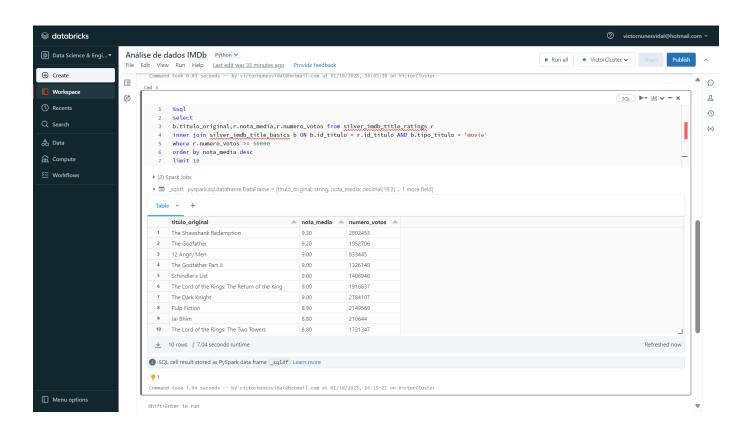
ETAPA 12 – ANÁLISE DOS DADOS



Ao fazer a primeira query para trazer os filmes com maior nota, percebi que apareceram filmes bem desconhecidos e com pouquíssimas avaliações.

Dessa forma, vamos estabelecer um critério para as maiores notas: somente filmes com mais de 50 mil avaliações.

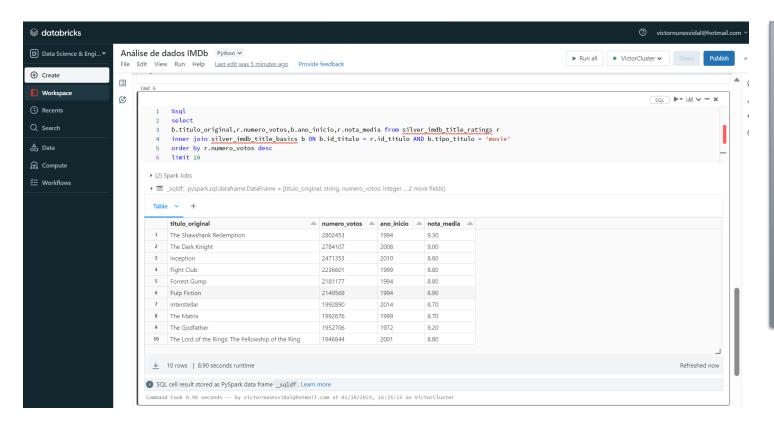
ETAPA 13 – ANÁLISE DOS DADOS



Agora sim, ao colocar um filtro, trazemos os 10 filmes com as maiores notas.

O primeiro colocado é o filme "The Shawshank Redemption" (no Brasil, "Um Sonho de Liberdade"), lançado em 1994. O filme foi avaliado por 2,8 milhões de usuários no IMDb.

ETAPA 14 – ANÁLISE DOS DADOS

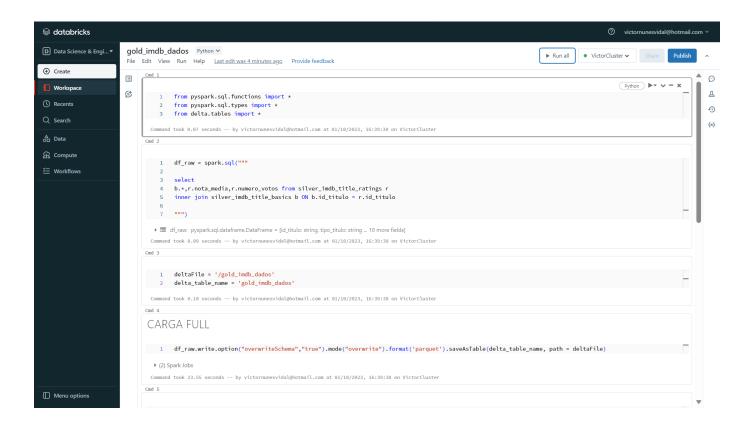


Para responder à 2^a pergunta proposta, sobre quais são os filmes mais populares, fazemos uma ordenação pelo campo numero votos.

Quatro filmes dessa lista de mais populares também estão na lista de mais bem avaliados feita anteriormente.

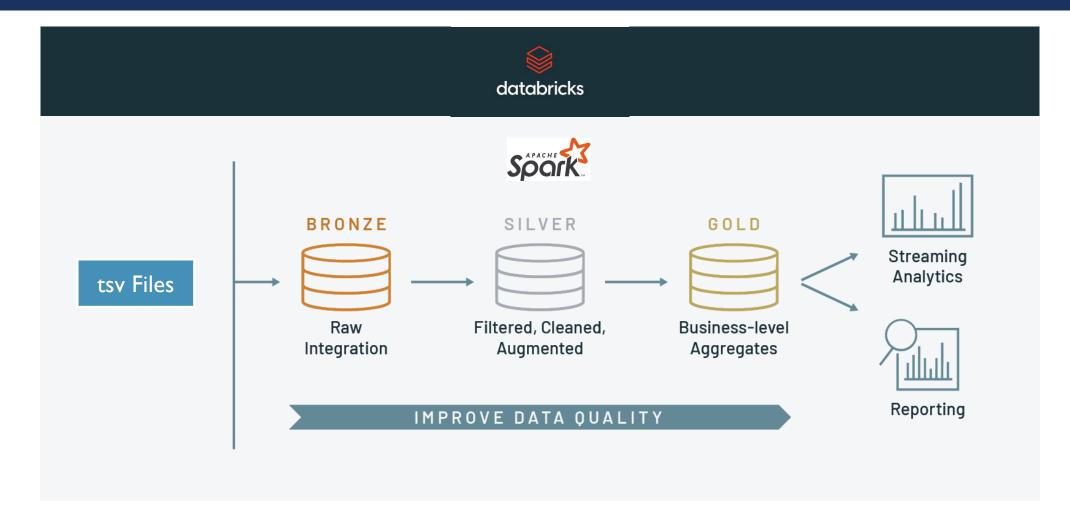
O líder é o mesmo: "The Shawshank Redemption".

ETAPA 15 – CAMADA GOLD



Não seria necessário criar a tabela Gold agora, mas criei a mesma, a fim de facilitar futuras análises.

ETAPA 15 – ARQUITETURA





OBRIGADO

VICTORNUNESVIDAL@HOTMAIL.COM